

KGŠM

Ako Google určuje dôležitosť webstránok?

Lukáš Lafférs

KM FPV UMB
www.lukaslaaffers.com

14. November, 2022



Google Search

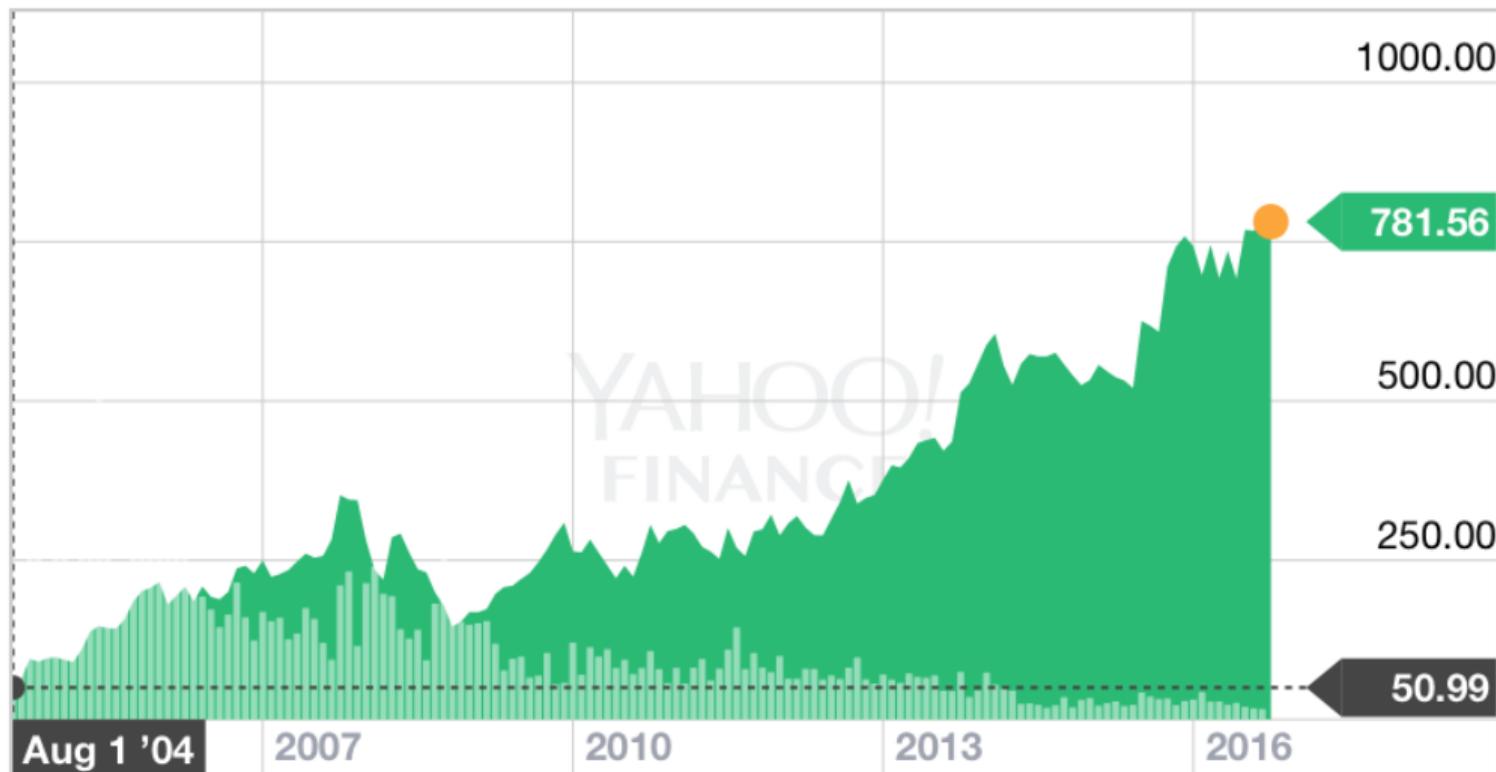
I'm Feeling Lucky

Google.sk offered in: [slovenčina](#)

1D 5D 1M 6M YTD 1Y 2Y 5Y 10Y

MAX

↗ Interactive chart



Larry Page a Sergey Brin



Larry Page a Sergey Brin

- PhD študenti na Stanfordskej Univerzite
- 1999 - algoritmus PageRank
- patent → \$1,8 mil. → \$336 mil.

Príklad

Google Banska Bystrica

Web Maps Images News Videos More ▾ Search tools

About 951,000 results (0.82 seconds)

Banská Bystrica - Wikipedia, the free encyclopedia
https://en.wikipedia.org/wiki/Bansk%C3%A1_Bystrica ▾ Wikipedia ▾
The earliest history of Banská Bystrica was connected with the exploitation of its abundant deposits of copper (and to a lesser extent of silver, gold, and iron).
History - Etymology - Geography - Demographics

Images for banská bystrica Report images



More images for banská bystrica

Banská Bystrica
www.banskabystrica.sk/ ▾ Translate this page Banská Bystrica ▾
Oficiálne stránky mesta Banská Bystrica, informácie z činnosti samosprávy mesta , vzdelanie, kultúra a šport.

Banská Bystrica EN
eng.banskabystrica.sk/ ▾ Translate this page Banská Bystrica ▾
The city of Banská Bystrica is located in central Slovakia. Banská Bystrica is the most important historical, cultural and economic centre of the central Slovakia.

Problém

Chceme usporiadať stránky podľa dôležitosti.

Ako ?

Čo majú dôležité stránky spoločné?

- Existujú stránky, ktoré na ne odkazujú.
- Existuje veľa stránok, ktoré na ne odkazujú.
- Existuje veľa **dôležitých** stránok, ktoré na ne odkazujú.

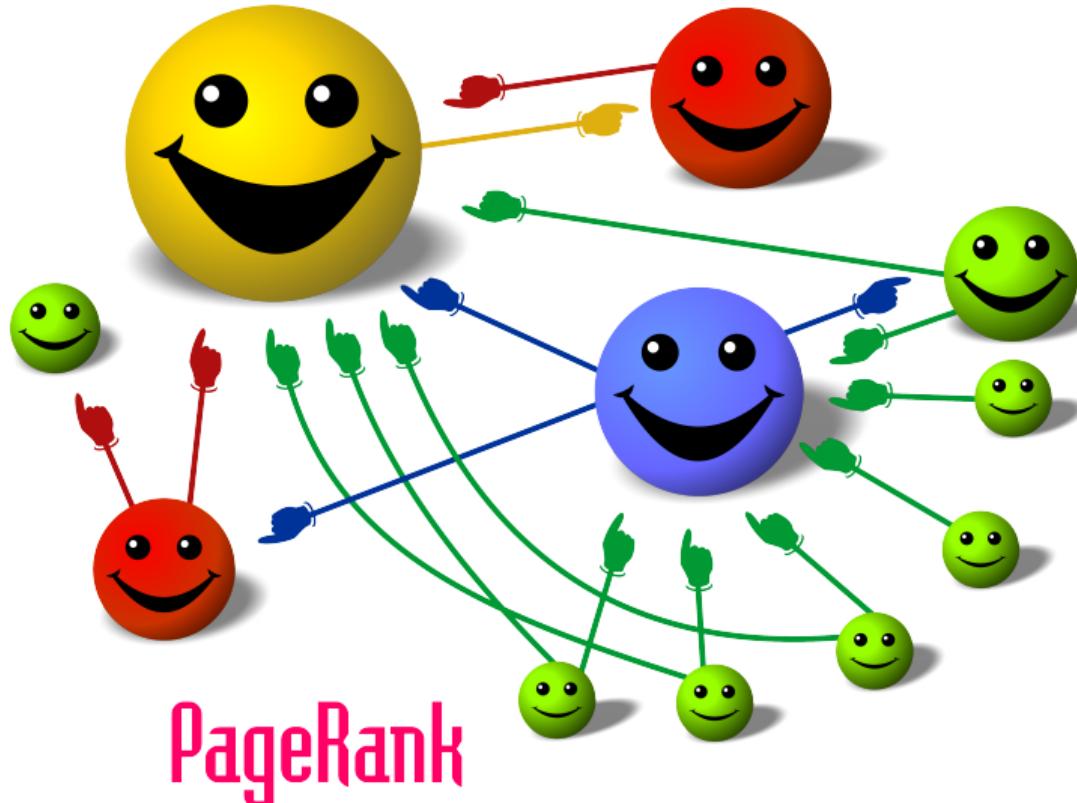
Príklady dôležitých stránok:

- www.wikipedia.org
- www.google.com
- www.twitter.com
- www.facebook.com
- www.nasa.gov
- www.microsoft.com

Príklady menej dôležitých stránok:

- www.akozasaditcibulu.sk
- www.akozasaditcesnak.sk
- www.varimecibulu.sk
- www.varimecviklu.sk
- www.akoneprevaritcviklu.sk
- www.lukaslaffers.com

Web ako siet stránok



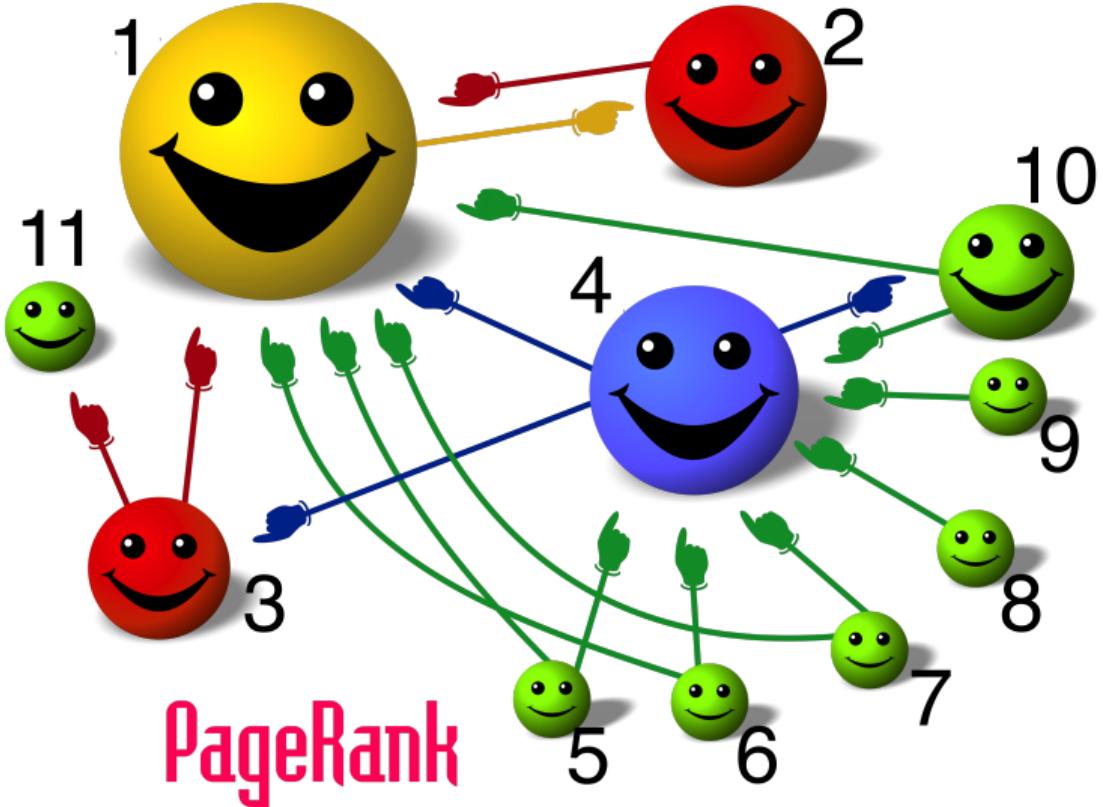
Problém náhodného surfujúceho

Náhodný surfujúci prišiel na nejakú webstránku, čo urobí?



- S pravdepodobnosťou 85% štukne na náhodný odkaz
- S pravdepodobnosťou 15% zatvorí browser a ide na úplne inú, náhodnú stránku

Náhodný surfujúci si nič nepamätá, len štuká a štuká...



Pravdepodobnosti prechodu medzi stránkami

$$M = \begin{pmatrix} 0 & 0.5 & 0 & 0.5 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0.33 & 0 & 0.33 & 0 & 0 & 0 & 0 & 0 & 0 & 0.33 \\ 0.5 & 0 & 0 & 0.5 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0.5 & 0 & 0 & 0.5 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0.5 & 0 & 0 & 0.5 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0.5 & 0 & 0 & 0.5 & 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$



Zavriem browser a štuknem na náhodnú stránku

$$N = \begin{pmatrix} 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 \\ 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 \\ 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 \\ 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 \\ 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 \\ 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 \\ 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 \\ 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 \\ 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 \\ 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 & 0.1 \end{pmatrix}$$



Náhodne štukajúci surfer

$$0.85M + 0.15N$$

Náhodne štukajúci surfer

$$P = \begin{pmatrix} 0.015 & 0.440 & 0.015 & 0.440 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 \\ 0.865 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 \\ 0.865 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 \\ 0.298 & 0.015 & 0.298 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 & 0.298 \\ 0.440 & 0.015 & 0.015 & 0.440 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 \\ 0.440 & 0.015 & 0.015 & 0.440 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 \\ 0.440 & 0.015 & 0.015 & 0.440 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 \\ 0.015 & 0.015 & 0.015 & 0.865 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 \\ 0.015 & 0.015 & 0.015 & 0.865 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 \\ 0.440 & 0.015 & 0.015 & 0.440 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 & 0.015 \end{pmatrix}$$



0.85 *



0.15 *

Koľko percent času strávi náhodne štukajúci surfer na nejakej webstránke?

Čím viacej, tým je stránka dôležitejšia!

Náhodne štuká, na ktorej stránke bol najviackrát?

alebo

Veľa surfujúcich. Na ktorej stránke ich je najviac?

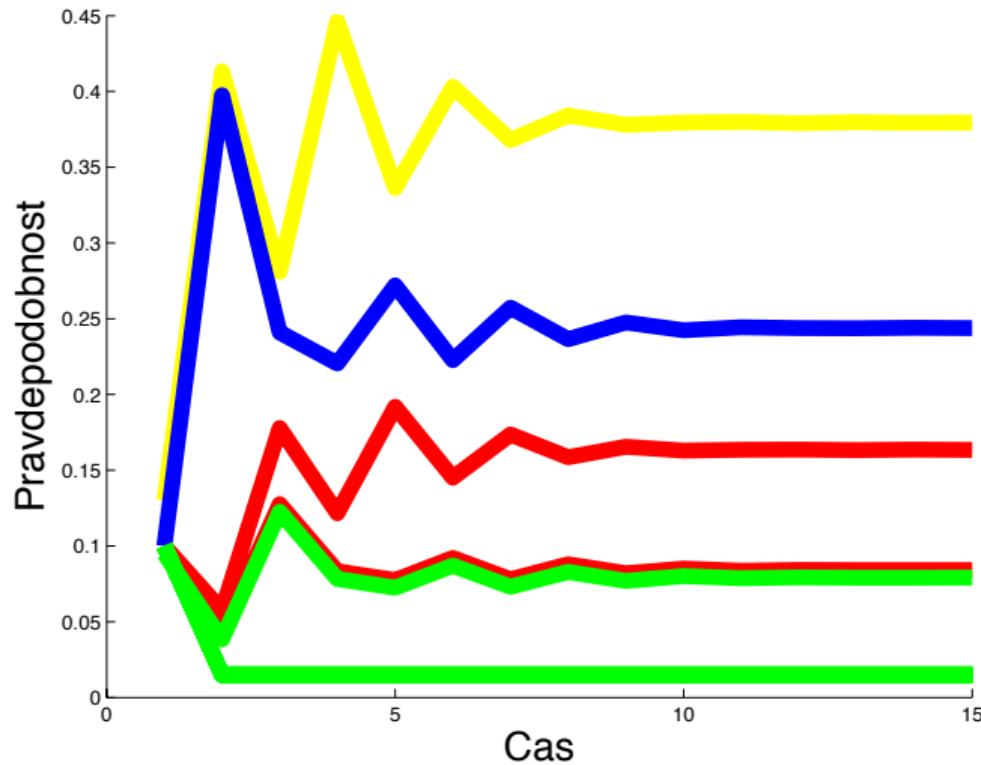
Veľa surfujúcich

Na ktorej stránke začnú?

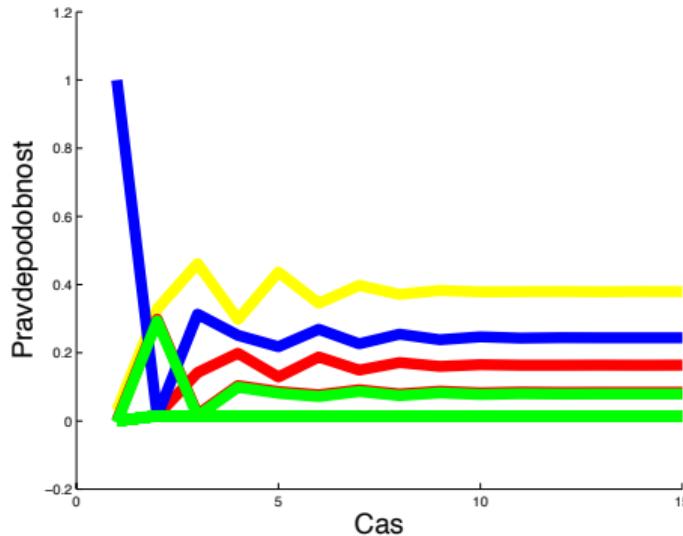
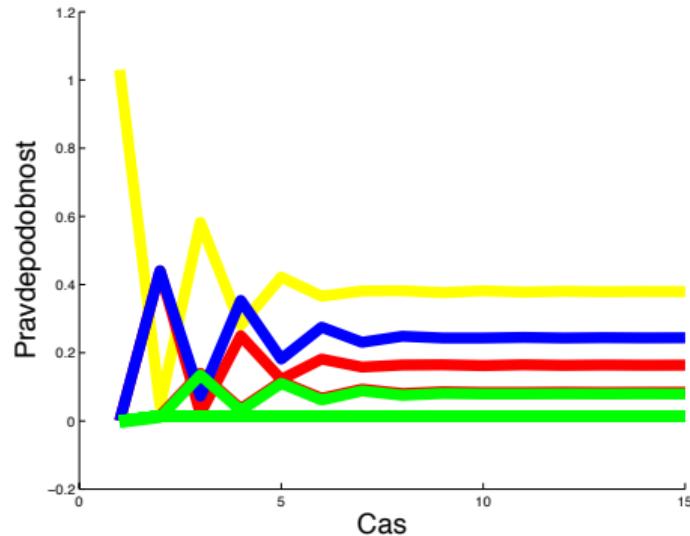
Napr.:

- Na každej stránke rovnako veľa.
- Všetci začnú na tej istej stránke.

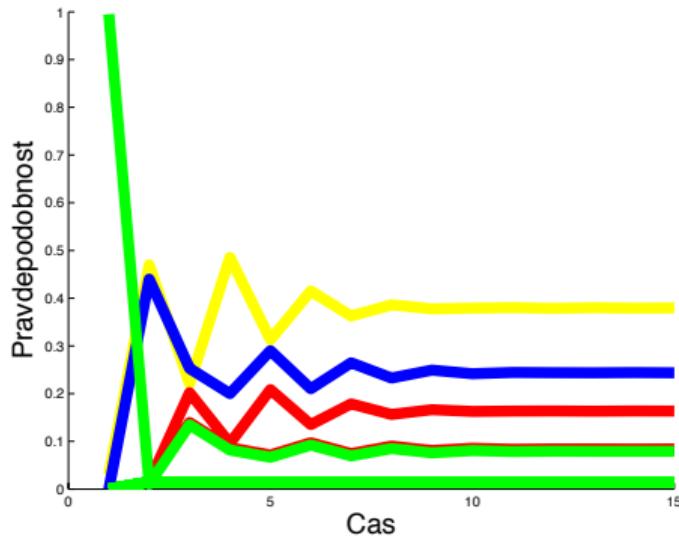
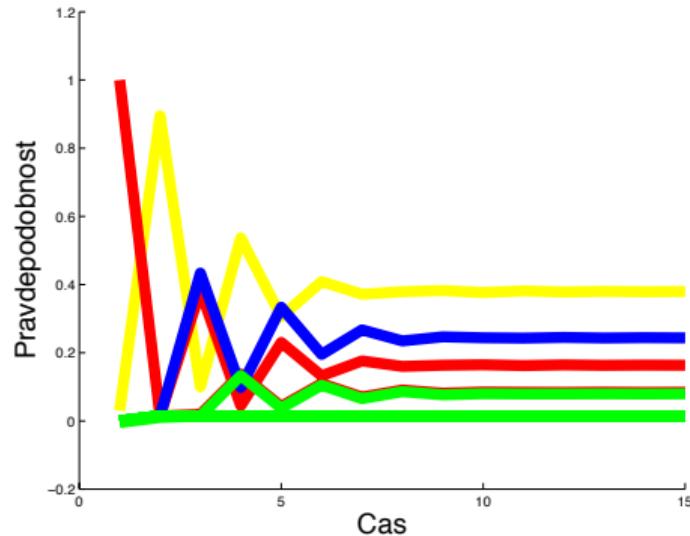
Rozdelím ich spravodlivo

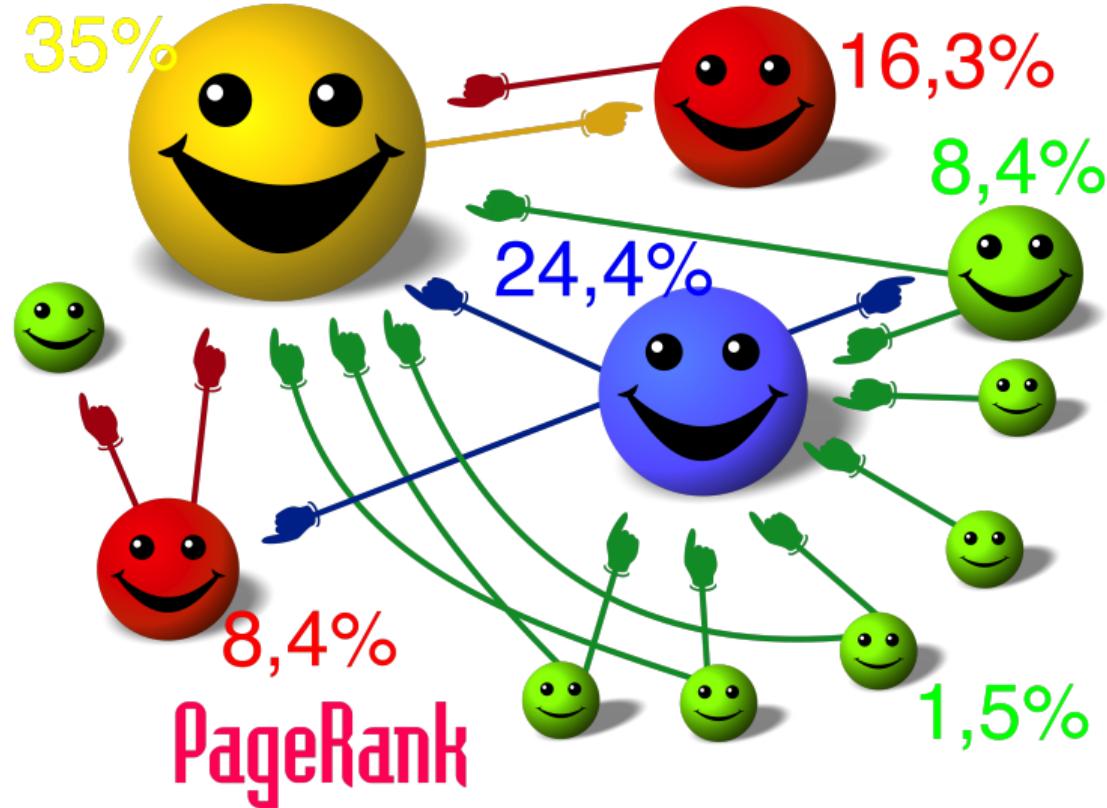


Rozdelím ich nespravodlivo (1)



Rozdelím ich nespravodlivo (2)





Nech ich rozdelíme akokoľvek, za nejaký čas to bude vyzerať vždy rovnako.

Toto rozdelenie sa nazýva **stacionárne**.



```
pagerank.m x +
1 % PageRank example
2
3 % zostrojime maticu susednosti
4 - clear all
5
6 - Susednosti = zeros(10,10);
7 - Susednosti(1,2) = 1;
8 - Susednosti(1,4) = 1;
9 - Susednosti(2,1) = 1;
10 - Susednosti(3,1) = 1;
11 - Susednosti(4,[1 3 10]) = [1 1 1];
12 - Susednosti(5,[1 4]) = [1 1];
13 - Susednosti(6,[1 4]) = [1 1];
14 - Susednosti(7,[1 4]) = [1 1];
15 - Susednosti(8,4) = 1;
16 - Susednosti(9,4) = 1;
17 - Susednosti(10,[1 4]) = [1 1];
18
19 - n = 10;
20
21 - MaticaPrechodu =...
22 -     Susednosti.*...
23 -     (1./sum(Susednosti)').*...
24 -     ones(1,n));
25
26 - MaticaZmeny = (1/n)*ones(n,1)*ones(1,n);
27
28 - pravdZmeny = 0.15;
29
30 - M = MaticaZmeny*pravdZmeny + MaticaPrechodu*(1-pravdZmeny);
31
32 - MM = M^100;
33
34 - stacionarnaDistribucia = MM(1,:);
35
```

Nie je to až tak jednoduché

Naš príklad: 10 webstránok

Google: 130 000 000 000 webstránok (Nov 2016).

- To ako Google usporiadava stránky je v skutočnosti extrémne tajná a cenná informácia
- Ich algoritmus používa niekoľko stoviek typov informácií na to, aby odporučil tú najlepšiu stránku
- Každý rok implementujú okolo 500 zmien a urobia viac ako 20000 experimentov
- TrustRank - dôveryhodnejšie stránky sú dôležitejšie
- Google je dobrý v odhalovaní toho, kto sa snaží okabátiť PageRank
- Je oveľa ľahšie zvýšiť $PR7 \rightarrow PR8$ ako $PR1 \rightarrow PR2$

Stacionárne rozdelenie je v prípade Google riešenie veľa rovníc o veľa neznámych.

Znalosťami z algebry však vieme, že hľadáme tzv. **vlastný vektor** a na to poznáme sofistikované spôsoby ako to vyrátať aj pre obrovské množstvo webstránok.

$$\pi = \pi P$$

$$P = \begin{bmatrix} \text{Sunny} & \text{Cloudy} \\ \text{Cloudy} & \text{Rainy} \end{bmatrix} = \begin{bmatrix} 0.8 & 0.2 \\ 0.5 & 0.5 \end{bmatrix}$$

Dnes je ☀

Aké počasie bude o polroka?

$$\pi = \pi \begin{bmatrix} \text{Sunny} & \text{Cloudy} \\ \text{Cloudy} & \text{Rainy} \end{bmatrix}$$

$$\pi = [0.714, 0.285]$$

$$Pr(\text{Sunny}) = 71.4\%$$

$$Pr(\text{Rainy}) = 28.5\%$$

$$P = \begin{bmatrix} \text{Sunny} & \text{Cloudy} \\ \text{Cloudy} & \text{Rainy} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0.5 & 0.5 \end{bmatrix}$$

Dnes je ☀

Aké počasie bude o polroka?

$$Pr(\text{Sunny}) = 99.999999\dots\%$$

$$Pr(\text{Rainy}) = 0.0000\dots1\%$$

Náhodný proces surfujúceho sa volá **Markovov retazec** s prechodovými pravdepodobnosťami danými tabuľkou P .

- Modelovanie rizikovosti finančných produktov
- Správanie sa dynamiky plynov
- Modelovanie aktivity enzýmov
- Rozoznávanie reči
- Optimalizácia telekomunikačných sietí
- Makroekonomické modelovanie
- Genetika
- Počasie
- Predikovanie víťazstva v bejzbale

Zhrnutie

- Larry Page a Sergey Brin sa v roku 1996 zaobrali otázkou ako zoradiť webstránky podľa dôležitosti
- Nápad náhodného surfujúceho im umožnil jednoduchú matematickú formuláciu problému
- Na riešenie tohto problému potom vedeli použiť efektívne algoritmy
- ich myšlienka zmenila spôsob akým dnes vyhľadávame informácie

Ďakujem za pozornosť!