

# Lineárna Regresia 1

## Prednáška č.10

Lukáš Lafférs

KM FPV UMB  
[www.lukaslaffers.com](http://www.lukaslaffers.com)

# Scvrkávacie metódy (shrinkage methods)

Máme príliš veľa regresorov?

Ako využiť túto informáciu?

# PCA

100 pozorovaní

40 premenných

$X$  je matica 100 krát 40

# Začíname

Nastavíme  $u_1$  (vektor rozmeru 40) tak, aby

$$\text{var}(Xu_1) \rightarrow \max$$

Okrem toho budeme požadovať, aby  $u_1^T u_1 = 1$  (aby bol vektor  $u_1$  jednoznačne definovaný).

$Xu_1$  je **prvý hlavný komponent**

# Pokračujeme

Nastavíme  $u_2$  tak, aby

$$\text{var}(Xu_2) \rightarrow \max$$

zatiaľčo  $u_2^T u_1 = 0$  a zároveň  $u_2^T u_2 = 1$ .

$Xu_2$  je **druhý hlavný komponent**

## Pokračujeme

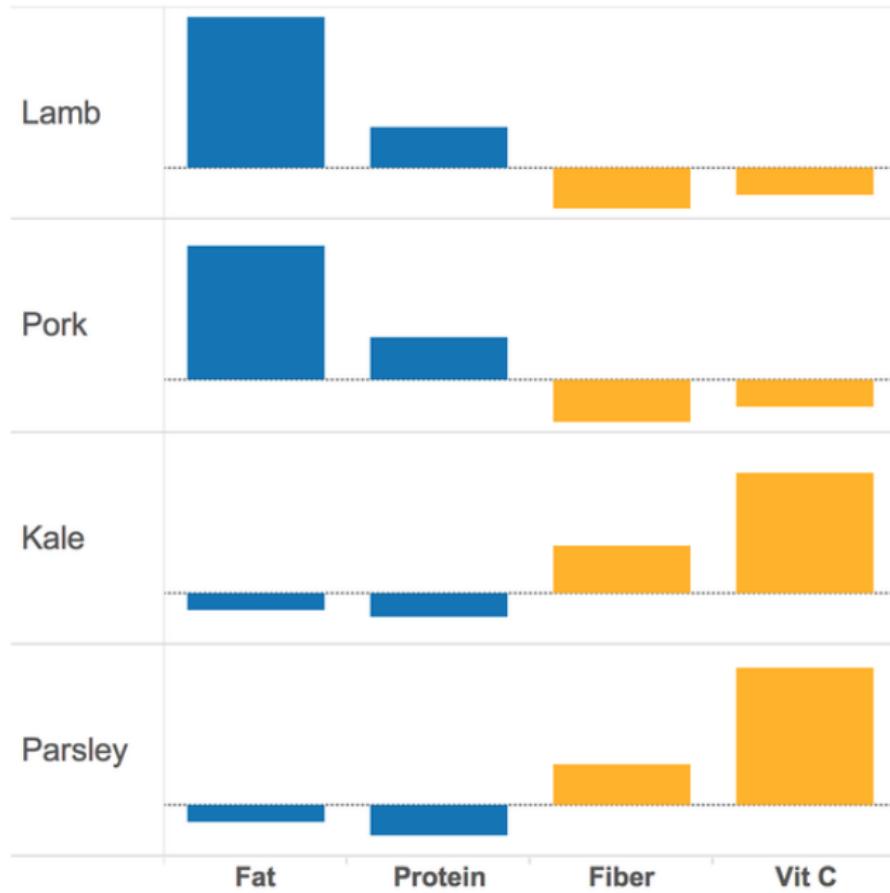
Týmto spôsobom pokračujeme a vieme reprezentovať každý bol v oblaku bodov matice  $X$  ako jednoznačnú lineárnu kombináciu hlavných komponentov.

Pointou je, že napríklad 5 hlavných komponentov môže vysvetliť až 99% variácie v  $X$ . To znamená, že nepotrebujeme 40 čísel na reprezentovanie jedného porozorania ale stačí nám napr. len 5.

# Hlavné komponenty

- sú ortogonálne čo je výhodné, ak ich používame ako prediktory v regresii, lebo pridaním ďalšieho hlavného komponentu sa nám nezmenia odhady parametrov. Okrem toho odhady sú numericky stabilnejšie.
- môžu šetriť pamäť alebo miesto na disku.
- môžu ale nemusia byť interpretovateľné. Niekedy tým, že vidíme akej lineárnej kombinácií  $u_1$  zodpovedá prvý komponent, tak môžeme pochopiť o čo ide, a to nám vie pridať vhľad do problematiky.
- nám môžu pomôcť odhaliť zhľuky podobných bodov. V 40 rozmeroch nás častokrát naša intuícia opúšťa.

# Príklad 1



# Príklad 1 - Factor Loadings

	PC1	PC2	PC3	PC4
Fat	-0.45	0.66	0.58	0.18
Protein	-0.55	0.21	-0.46	-0.67
Fiber	0.55	0.19	0.43	-0.69
Vitamin C	0.44	0.70	-0.52	0.22

Obr. 2: Zdroj:

<https://www.quora.com/What-is-an-intuitive-explanation-for-PCA>

# Príklad 1



# Guinea Hen



Obr. 4: Zdroj: wiki

## Príklad 2

Sample of original faces before running PCA:



Obr. 5: Zdroj: <https://github.com/gbuesing/pca/tree/master/examples>

## Príklad 2 - rekonštrukcia pomocou 36 hlavných komponentov



Obr. 6: Zdroj: <https://github.com/gbuesing/pca/tree/master/examples>

## Príklad 2 - 'Eigenfaces'



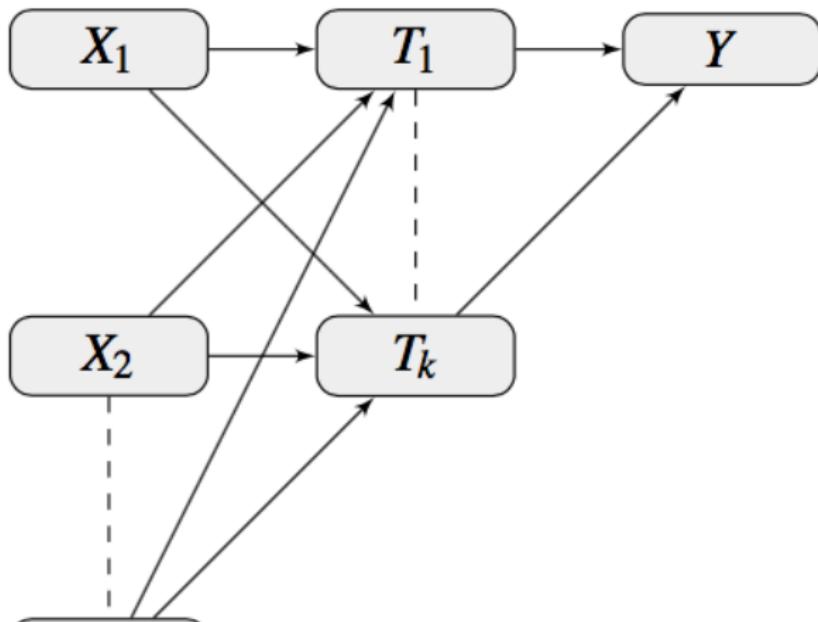
Obr. 7: Zdroj: <https://github.com/gbuesing/pca/tree/master/examples>

# Partial Least Squares

Našou úlohou je nájsť také ortogonálne kombinácie  $T_1, \dots, T_k$  prediktorov  $X_1, \dots, X_p$ , že predikcia

$$\hat{y} = \beta_1 T_1 + \dots + \beta_k T_k,$$

je čo najlepšia možná. Na odhadnutie  $T_i$  sú rôzne algoritmy a ich počet sa vyberá pomocou krízovej validácie.



# Ridge regression

Ako zostabilniť odhady parametrov? Tak, že im "zakážeme" príliš veľké hodnoty. Toto môžeme urobiť viacerými spôsobmi. Jedným z nich je hrebeňová regresia. Namiesto minimalizácie štvorcov, minimalizujeme

$$(y - X\beta)^T(y - X\beta) + \lambda \sum_j \beta_j^2$$

čo je ekvivalentné s

$$(y - X\beta)^T(y - X\beta) \text{ subject to } \sum_j \beta_j^2 \leq t^2.$$

Odhad je  $\hat{\beta} = (X^T X + \lambda I)^{-1} X^T y$ . Toto je príklad penalizovanej regresie.  
Pre  $\lambda \rightarrow 0$  dostávame  $\hat{\beta} \rightarrow \hat{\beta}_{LS}$  a pre  $\lambda \rightarrow \infty$  dostávame  $\hat{\beta} \rightarrow 0$ .

Parameter  $\lambda$  nastavíme pomocou krízovej validácie.

Odhad parametrov je vychýlený ale to je cena, ktorú platíme za stabilnejší, teda menej variabilný odhad.

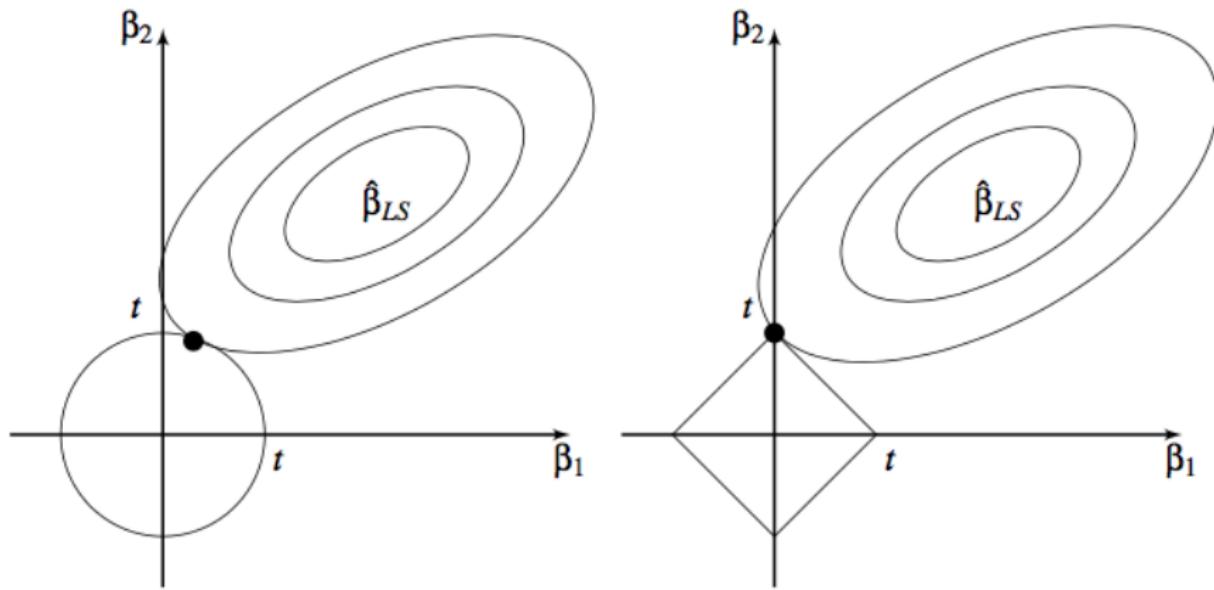
# LASSO

$$(y - X\beta)^T(y - X\beta) + \lambda \sum_j |\beta_j|$$

čo je ekvivalentné s

$$(y - X\beta)^T(y - X\beta) \text{ subject to } \sum_j |\beta_j| \leq t$$

Výhodou Lassa je, že vďaka tvaru penalty niektoré parametre priamo vynuluje. Preto akoby robil výber modelu aj odhadovanie modelu naraz! Lasso je rozumné používať ak sa domnievame, že existuje niekoľko silných efektov a veľa iných prediktorov nemá na odozvu žiadnen vplyv.



Obr. 9: Stratová funkcia má minimum v  $\hat{\beta}_{LS}$ , tam sa dosahuje najlepší fit.

Penalta  $\lambda$  však posúva optimum blišie k nule (scvrkáva parametre), a to na kružnicu (vľavo ridge:  $\sum_{j=1}^p \beta_j^2 = t^2$ ) alebo štvorec (vpravo LASSO :

$$\sum_{j=1}^p |\beta_j| = t$$

Ďakujem za pozornosť.